

Exercice 1:

1. D'après le cours, le risque de Bayes associé à l'erreur de classification est égal à:

$$\mathbb{E} [\min (\eta(x), 1-\eta(x))]$$

Comme $\frac{x}{x+\theta} < \frac{1}{2} \Leftrightarrow 2x < x+\theta \Leftrightarrow x < \theta$,

on a:

$$\mathbb{E} [\min (\eta(x), 1-\eta(x))] = \mathbb{E} \left[\frac{x}{x+\theta} \mathbb{1}_{\{x \leq \theta\}} \right] + \mathbb{E} \left[\left(1 - \frac{x}{x+\theta} \right) \mathbb{1}_{\{x > \theta\}} \right]$$

$$= \frac{1}{2\theta} \int_0^\theta \frac{x}{x+\theta} dx + \frac{1}{2\theta} \int_\theta^{2\theta} \frac{\frac{\theta}{x+\theta}}{\frac{\theta}{x+\theta}} dx$$

$$= \frac{1}{2\theta} \int_0^\theta \frac{\theta}{x+\theta} + 1 dx + \frac{1}{2} \left[\ln(x+\theta) \right]_\theta^{2\theta}$$

$$= \frac{1}{2} - \frac{1}{2} \left[\ln(x+\theta) \right]_0^\theta + \frac{1}{2} \ln \left(\frac{(1+\alpha)\theta}{2\theta} \right)$$

$$= \frac{1}{2} - \frac{1}{2} \ln \left(\frac{2\theta}{\theta} \right) + \frac{1}{2} \ln \left(\frac{(1+\alpha)}{2} \right)$$

$$= \boxed{\frac{1}{2} \left(1 + \ln \left(\frac{1+\alpha}{2} \right) \right)}$$

2. (a)

(2)

$$L(g) = \mathbb{E}[l(Y, g(X))] = P(Y=1, g(X)=0) + P(Y=0, g(X)=1) + \lambda P(g(X)=1)$$

$$= \int \underbrace{P(Y=1/X=x)}_{\eta(x)} \mathbb{1}_{\{g(x)=0\}} P_X(dx) + \int \underbrace{P(Y=0/X=x)}_{(1-\eta(x))} \mathbb{1}_{\{g(x)=1\}} P_X(dx) + \int \lambda \mathbb{E}[\mathbb{1}_{\{g(x)=1\}}]$$

$$= \mathbb{E}[\eta(X) \mathbb{1}_{\{g(X)=0\}} + (1-\eta(X)) \mathbb{1}_{\{g(X)=1\}} + \lambda \mathbb{1}_{\{g(X)=1\}}]$$

d'où le résultat.

(b) Pour déterminer g^* , on résout dans un premier temps l'inégalité $1 + \lambda - p \leq p \Leftrightarrow p \geq \frac{1+\lambda}{2}$.
($p \in [0,1]$)

On pose alors:

$$g^*(x) = \begin{cases} 0 & \text{si } \eta(x) \leq \frac{1+\lambda}{2} \\ 1 & \text{si } \eta(x) > \frac{1+\lambda}{2} \end{cases}$$

Par construction, $\forall x \in \mathcal{X}$,

- 1) $\forall g, (1+\lambda-\eta(x)) \mathbb{1}_{\{g(x)=1\}} + \eta(x) \mathbb{1}_{\{g(x)=0\}} \geq \min(1+\lambda-\eta(x), \eta(x))$
- 2) $(1+\lambda-\eta^*(x)) \mathbb{1}_{\{g^*(x)=1\}} + \eta^*(x) \mathbb{1}_{\{g^*(x)=0\}} = \min(1+\lambda-\eta(x), \eta(x))$

On en déduit donc que:

$$L(g^*) = \mathbb{E}[\min(1+\lambda-\eta(X), \eta(X))] \leq L(g) \quad \forall g.$$

puis que:

$$g^* = \underset{g}{\operatorname{Argmin}} L(g) \quad \text{et} \quad \text{risque optimal} = L(g^*).$$

(3)

Exercice 2:

$$L(\theta) = \frac{1}{2N} \sum_{k=1}^N \Psi(y_i, \langle x_i, \theta \rangle) + \lambda \left(\alpha \| \theta_1 \|^2 + (1-\alpha) \frac{\| \theta_2 \|^2}{2} \right) \quad \underbrace{\quad}_{P_\lambda(\theta)}$$

1) Si $\Psi(y, z) = y \frac{e^z}{1+e^z} + (1-y) \frac{1}{1+e^z}$, alors

$$L(\theta) = \underbrace{\frac{1}{2N} \sum_{k=1}^N y_i \frac{e^{\langle x_i, \theta \rangle}}{1+e^{\langle x_i, \theta \rangle}} + (1-y_i) \frac{1}{1+e^{\langle x_i, \theta \rangle}}}_{\textcircled{A}} + \underbrace{P_\lambda(\theta)}_{\textcircled{B}}.$$

A un facteur 2 près, \textcircled{A} correspond à la log. vraisemblance associée à la régression logistique, i.e. $\pi(x, \theta) = \frac{e^{\langle x, \theta \rangle}}{1+e^{\langle x, \theta \rangle}}$

tandis que $P_\lambda(\theta)$ désigne une pénalité de type Elastic Net. On a donc ici un estimateur associé à la régression logist. que pénalisée avec pénalité Elastic Net.

Sur R, ça donne -

glmnet (\hat{X} , Y , family = "binomial", s = 1, alpha = α)
 ↑ ↑
 matrice de vecteur
 design des réponses

2. (a) $\theta \mapsto \langle x, \theta \rangle$ est convexe, ϕ et $u \mapsto u^2$ le sont également donc par composition, $\theta \mapsto (y - \phi(\langle x, \theta \rangle))^2$ l'est également. Or ailleurs $\theta \mapsto \langle \theta, u_1 \rangle$ et $\theta \mapsto \langle \theta, u_2 \rangle$ sont clairement convexes. On a donc une somme de fonctions convexes qui est donc convexe.

$$(b). \quad \partial_{\theta_j} \left[(y - \phi(\langle x, \theta \rangle))^2 \right] = 2(\phi(\langle x, \theta \rangle) - y) \cdot \partial_{\theta_j}(\phi(\langle x, \theta \rangle))$$

$$(a), \quad \partial_{\theta_j}(\phi(\langle x, \theta \rangle)) = \phi'(\langle x, \theta \rangle) \cdot x_j.$$

$$\text{Donc} \quad \partial_{\theta_j} \left[(y - \phi(\langle x, \theta \rangle))^2 \right] = 2(\phi(\langle x, \theta \rangle) - y) \cdot \phi'(\langle x, \theta \rangle) \cdot x_j.$$

On en déduit donc que :

$$\begin{aligned} \partial_{\theta_j} L(\theta) = & \frac{1}{N} \sum_{i=1}^N \phi'(\langle x_i, \theta \rangle) \cdot \underset{\substack{\uparrow \\ \text{j-ième coord.}}}{x_i^j} (\phi(\langle x_i, \theta \rangle) - y_i) + \\ & + \lambda(1-\alpha) \theta_j + \underbrace{\begin{cases} \lambda\alpha \operatorname{sgn}(\theta_j) & \text{si } \theta_j \neq 0 \\ \lambda\alpha [-1, 1] & \text{si } \theta_j = 0. \end{cases}}_{(2)} \end{aligned}$$

(c) Si $\phi(x) = x$, alors,

$$\partial_{\theta_j} L(\theta) = \frac{1}{N} \sum_{i=1}^N x_i^j (\langle x_i, \theta \rangle - y_i) + \lambda(1-\alpha) \theta_j + (2).$$

Ainsi par le cours, $\theta \in \operatorname{Argmin} L \Leftrightarrow 0 \in \partial_{\theta_j} L(\theta).$

$$\Leftrightarrow \forall j, \begin{cases} \frac{1}{N} \sum_{i=1}^N x_i^j (\langle x_i, \theta \rangle - y_i) + \lambda(1-\alpha) \theta_j + \lambda\alpha \operatorname{sgn}(\theta_j) \text{ si } \theta_j \neq 0 \\ \frac{1}{N} \sum_{i=1}^N x_i^j (\langle x_i, \theta \rangle - y_i) + \lambda\alpha [-1, 1] \supset 0. & \text{si } \theta_j = 0. \end{cases}$$

(Naturalement, ça donne:)

(5)

$$\Leftrightarrow \begin{cases} \frac{1}{N} x_j^T (Y - x\theta) = \lambda(1-\alpha) \theta_j + \lambda\alpha \operatorname{sgn}(\theta_j) & \text{si } \theta_j \neq 0 \\ \left| \frac{1}{N} x_j^T (x\theta - Y) \right| \leq \lambda\alpha & \text{si } \theta_j = 0. \end{cases}$$

(où x_j = la j-ième colonne de X)

(b) $x^T z = \mathbb{I}_p \Rightarrow$ l'équation ci-dessus devient

$$\begin{cases} \frac{x_j^T Y}{N} = \left(\frac{1}{N} + \lambda(1-\alpha) \right) \theta_j + \lambda\alpha \operatorname{sgn}(\theta_j) & \text{si } \theta_j \neq 0 \\ \left| \frac{1}{N} \langle x_j, Y \rangle \right| \leq \lambda\alpha & \text{si } \theta_j = 0. \end{cases}$$

Ainsi, si $\frac{\langle x_j, Y \rangle}{N} > \lambda\alpha$, alors $\theta_j > 0$ et:

$$\theta_j = \left(\frac{1}{N} + \lambda(1-\alpha) \right)^{-1} \left(\frac{\langle x_j, Y \rangle}{N} - \lambda\alpha \right),$$

si $\frac{\langle x_j, Y \rangle}{N} < -\lambda\alpha$, alors $\theta_j < 0$ et:

$$\begin{aligned} \theta_j &= \left(\frac{1}{N} + \lambda(1-\alpha) \right)^{-1} \left(\lambda\alpha + \frac{\langle x_j, Y \rangle}{N} \right) \\ &= - \left(1 + \lambda N(1-\alpha) \right)^{-1} \left(\frac{|\langle x_j, Y \rangle|}{N} - \lambda\alpha \right) \end{aligned}$$

et enfin si $\left| \frac{1}{N} \langle x_j, Y \rangle \right| \leq \lambda\alpha$, alors $\theta_j = 0$.

La formule suit.

Exercice 3:

1. Voir TD

2. Voir TD (Exprimer en fonction de $\operatorname{Corr}(\hat{f}_{b_1}, \hat{f}_{b_2}) =: \rho$.

3. Du point de vue biais-variance, la réponse est pas vraiment.

Car par construction, le "biais est identique" et d'après

la question 2, la variance est toujours plus petite. Plus précisément,

$$\forall n, \mathbb{E} \left[\left(\frac{1}{B} \sum_{b=1}^B \hat{f}_b(x) - f(x) \right)^2 \right] \leq \operatorname{Biais}^2(\hat{f}_b) + \operatorname{Var}(\hat{f}_b)$$

Néanmoins \hat{f} n'est pas exactement l'estimateur de base car il est biaisé

sur un échantillon Bootstrap et non sur l'échantillon
d'apprentissage initial mais on peut supposer que l'influence sur
le biais est assez mineure.

⑥