Application des séries chronologiques sur les données Dataset_CB.csv

Ivanhoé & Youness

11 janvier 2024

Introduction

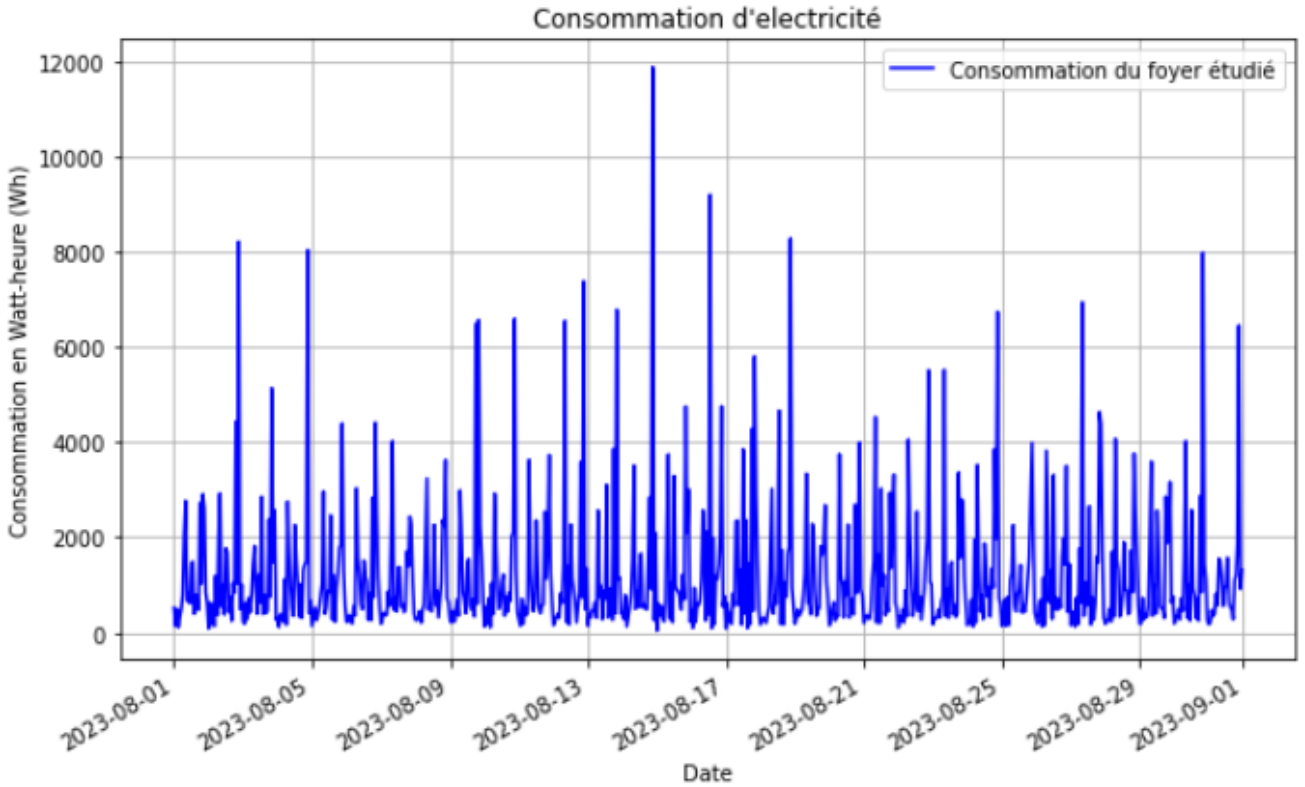

Voici une série chronologique de données pseudo-réelles issue d'une consommation EDF d'un foyer.

Problématique : Comment prédire à l'horizon de 7 jours la consommation électrique du foyer sur la première semaine de septembre 2023 ?

Renommer les colonnes et passer au format date

```
EDF = pd.read_csv(path)
EDF.columns = ["DATE","CONSO"] # renommer col
EDF.DATE = pd.to_datetime(EDF.DATE,format='%d/%m/%y %H:%M')
print("shape = ",EDF.shape)
EDF.head(4)
```

```
shape =  (744, 2)
```

Chargement des données

	DATE	CONSO
0	2023-08-01 00:00:00	522.646044
1	2023-08-01 01:00:00	142.889213
2	2023-08-01 02:00:00	497.052422
3	2023-08-01 03:00:00	110.082063

Dataset EDF

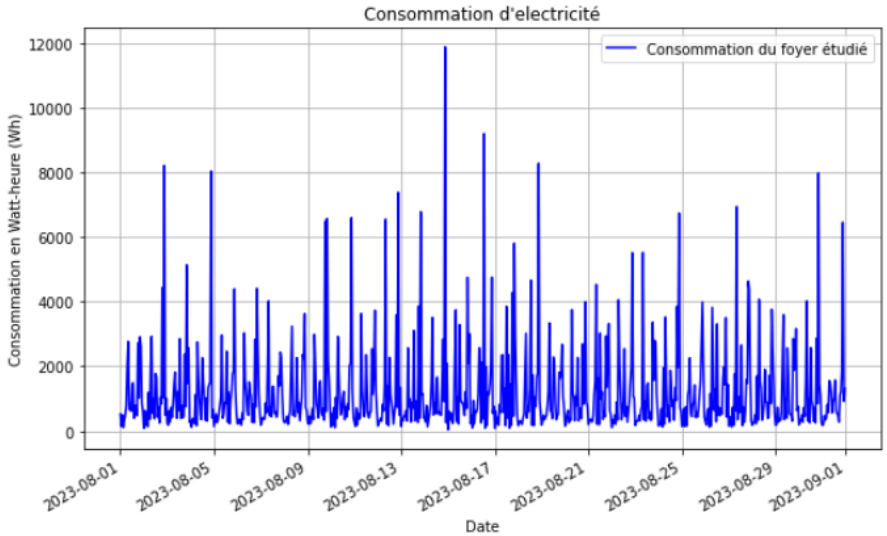

Consommation du foyer

Passage au log pour réduire la variabilité de la série

```
EDF['LOGCONSO'] = np.log(EDF.CONSO)
EDF.head()
```

	DATE	CONSO	LOGCONSO
0	2023-08-01 00:00:00	522.646044	6.258904
1	2023-08-01 01:00:00	142.889213	4.962070
2	2023-08-01 02:00:00	497.052422	6.208695
3	2023-08-01 03:00:00	110.082063	4.701226
4	2023-08-01 04:00:00	333.036926	5.808253

Dataset EDF

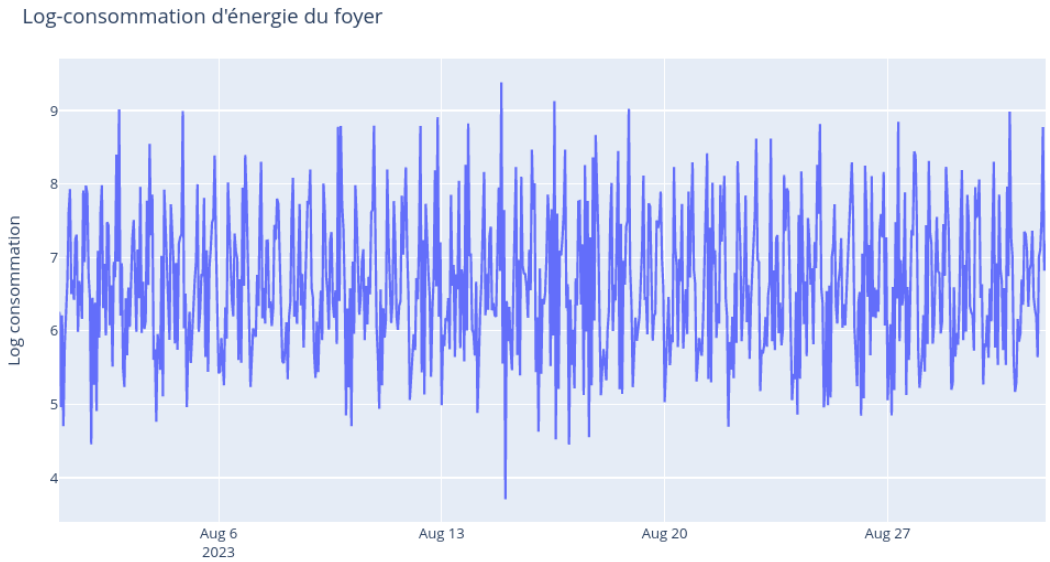

Log-consommation du foyer

Étude de la stationnarité de la log-consommation

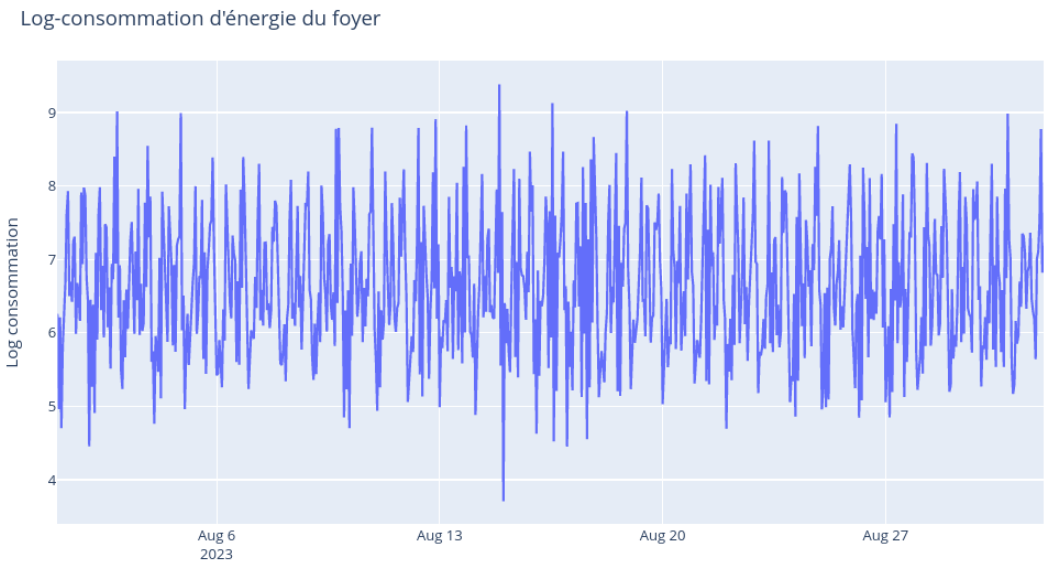

Log-consommation du foyer

Sans différentier

```
# Testons la non-stationnarité
TestA = adfuller(EDF.LOGCONSO) # Test ADF rejeté
print("ADF p-val : ", TestA[1])

# Testons la stationnarité
TestK = kpss(EDF.LOGCONSO) # Test KPSS non rejeté
print("KPSS p-val : ", TestK[1])# Test non rejeté
```

```
ADF p-val :  0.0
KPSS p-val :  0.1
```

Tests ADF et KPSS

Étude de la stationnarité de la log-consommation avec une différentiation saisonnière

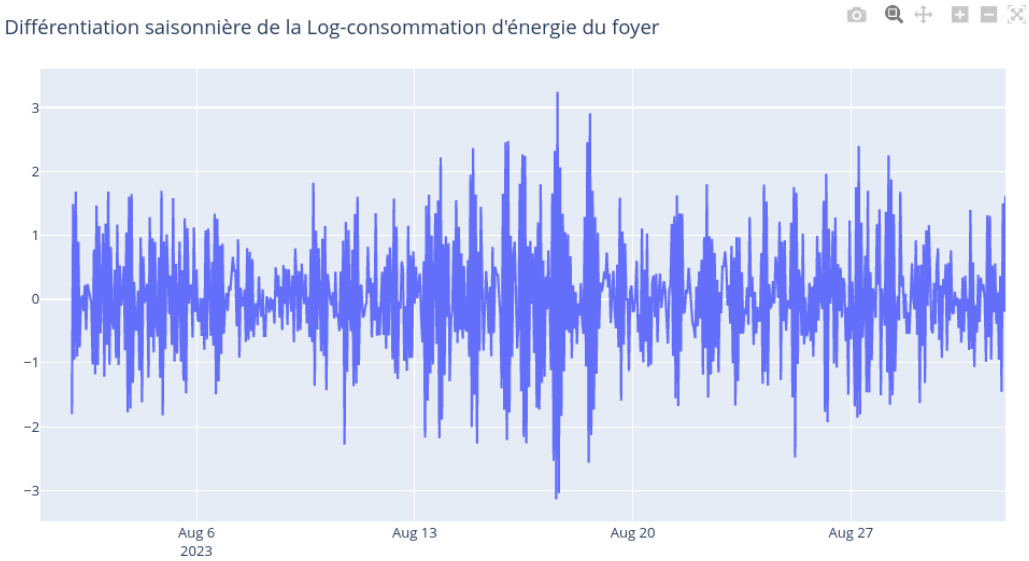

Différentielle saisonnière log-consommation du foyer

```
# On va différentier une fois pour regarder les incréments à 24 heures près
EDF["diff24"] = EDF.LOGCONSO.diff(24)
fig = px.line(EDF, x='DATE', y="diff24", labels={'DATE': 'Date', 'diff24': ''})
fig.update_layout(title="Différentiation saisonnière de la Log-consommation d'énergie du foyer")
fig.show()
```

Différentiation D=24

Avec différentiation saisonnière s=24

```
# Testons la non-stationnarité
TestA = adfuller(EDF.diff24.dropna()) # Test ADF rejeté au seuil de 5%
print("ADF p-val : ", TestA[1])

# Testons la stationnarité
TestK = kpss(EDF.diff24.dropna()) # Test KPSS non rejeté
print("KPSS p-val : ", TestK[1])# Test non rejeté
```

```
ADF p-val :  0.00022114078230846984
KPSS p-val :  0.1
```

Tests ADF et KPSS

Remarque

Attention avec les tests de stationnarité, l'hétéroscédasticité n'est pas toujours repérée.

Étude des corrélations sur la série passée au log

```
ACF = plot_acf(EDF.LOGCONSO, lags=70, alpha=0.05,title="ACF avec lags=70")
PACF = plot_pacf(EDF.LOGCONSO, lags=70, alpha=0.05,title="PACF avec lags=70")

ACF = plot_acf(EDF.LOGCONSO, lags=26, alpha=0.05,title="ACF avec lags=26")

PACF = plot_pacf(EDF.LOGCONSO, lags=26, alpha=0.05,title="ACF avec lags=26")
```

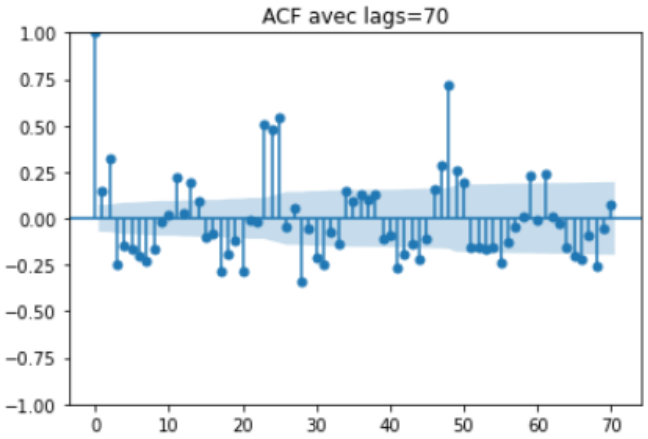

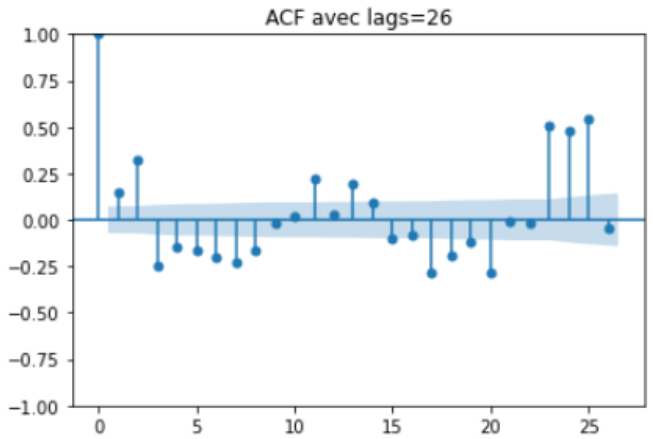

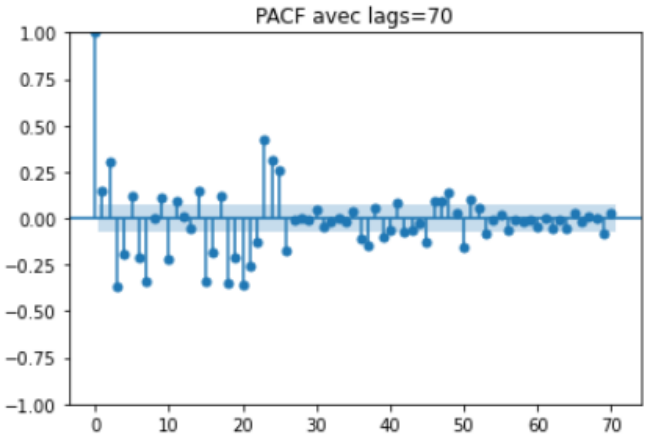

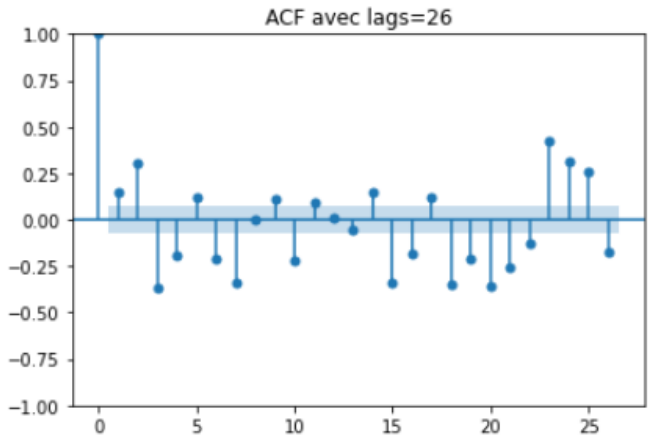

Recherche de modèles à l'aide de la fonction AUTO_ARIMA sous certaines contraintes

```
auto_arima(EDF.LOGCONSO, start_p=0, start_q=0, seasonal=True, start_P=0,
           start_Q=0, m=24, d=0, D=0, with_intercept=True, stepwise=True, trace=True)
#force D=d=0 # trace=True pour afficher # stepwise=True passe d'un modèle à l'autre
```

Best model : ARIMA(5,0,0)(1,0,2)[24] intercept

```
auto_arima(EDF.LOGCONSO, start_p=0, start_q=0,max_p = 5,
           max_q=3,seasonal=True, start_P=0, start_Q=0, m=24, d=1, D=0,
           with_intercept=True, stepwise=True, trace=True)
#force d=1 # trace=True pour afficher # stepwise=True passe d'un modèle à l'autre
```

Best model : ARIMA(1,1,0)(1,0,0)[24]

Remarque

Commandes qui mettent beaucoup de temps à s'exécuter.

Modèle 1 : SARIMAX(EDF.LOGCONSO, order=(5, 0, 0), seasonal_order=(1, 0, 2, 24), trend=None)

```
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT
                                     SARIMAX Results
==========================================================================================
Dep. Variable:                             LOGCONSO   No. Observations:                  744
Model:             SARIMAX(5, 0, 0)x(1, 0, [1, 2], 24)   Log Likelihood                -223.094
Date:                                 Mon, 08 Jan 2024   AIC                            464.188
Time:                                         15:05:41   BIC                            505.083
Sample:                                           0      HQIC                           480.001
                                                - 744
Covariance Type:                                  opg
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
ar.L1         -0.4553      0.035    -12.916      0.000      -0.524      -0.386
ar.L2          0.3228      0.039      8.222      0.000       0.246       0.400
ar.L3         -0.2471      0.044     -5.648      0.000      -0.333      -0.161
ar.L4         -0.1094      0.041     -2.680      0.007      -0.189      -0.029
ar.L5          0.2526      0.036      6.988      0.000       0.182       0.323
ar.S.L24       0.9999      0.000   8688.332      0.000       1.000       1.000
ma.S.L24      -1.3183      0.133     -9.899      0.000      -1.579      -1.057
ma.S.L48       0.3040      0.065      4.663      0.000       0.176       0.432
sigma2         0.0931      0.013      7.417      0.000       0.068       0.118
==========================================================================================
Ljung-Box (L1) (Q):                   0.19   Jarque-Bera (JB):                 1.14
Prob(Q):                              0.66   Prob(JB):                         0.57
Heteroskedasticity (H):               1.45   Skew:                             0.10
Prob(H) (two-sided):                  0.00   Kurtosis:                         2.98
==========================================================================================
```

```
plot1 = Mod1.plot_diagnostics(figsize=(10,10),lags=70)
```

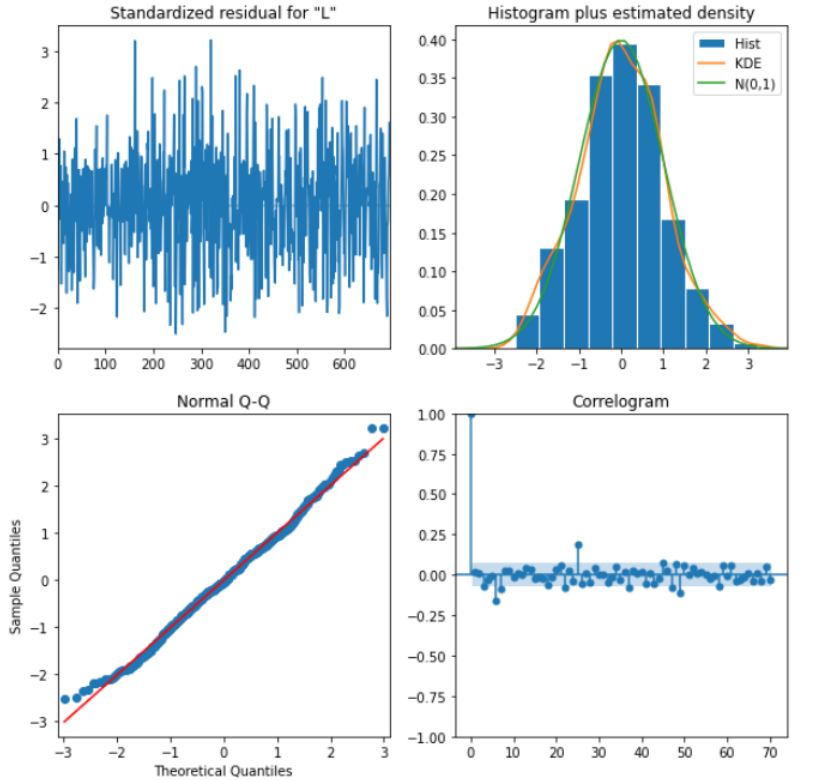

Modèle 2 : SARIMAX(EDF.LOGCONSO, order=(5, 0, 0), seasonal_order=(2, 0, 2, 24), trend=None)

Dep. Variable:	LOGCONSO	No. Observations:	744
Model:	SARIMAX(5, 0, 0)x(2, 0, [1, 2], 24)	Log Likelihood	-216.498
Date:	Mon, 08 Jan 2024	AIC	452.996
Time:	15:11:22	BIC	498.378
Sample:	0	HQIC	470.549
	- 744		
Covariance Type:	opg		

	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-0.4634	0.036	-12.723	0.000	-0.535	-0.392
ar.L2	0.2922	0.041	7.124	0.000	0.212	0.373
ar.L3	-0.2793	0.043	-6.479	0.000	-0.364	-0.195
ar.L4	-0.1498	0.039	-3.796	0.000	-0.227	-0.072
ar.L5	0.2477	0.036	6.869	0.000	0.177	0.318
ar.S.L24	0.2925	0.077	3.778	0.000	0.141	0.444
ar.S.L48	0.7074	0.077	9.138	0.000	0.556	0.859
ma.S.L24	-0.5115	0.154	-3.314	0.001	-0.814	-0.209
ma.S.L48	-0.4687	0.126	-3.717	0.000	-0.716	-0.222
sigma2	0.1004	0.015	6.905	0.000	0.072	0.129

Ljung-Box (L1) (Q):	1.58	Jarque-Bera (JB):	1.48
Prob(Q):	0.21	Prob(JB):	0.48
Heteroskedasticity (H):	1.46	Skew:	0.07
Prob(H) (two-sided):	0.00	Kurtosis:	2.82

```
plot2 = Mod2.plot_diagnostics(figsize=(10,10),lags=70)
```

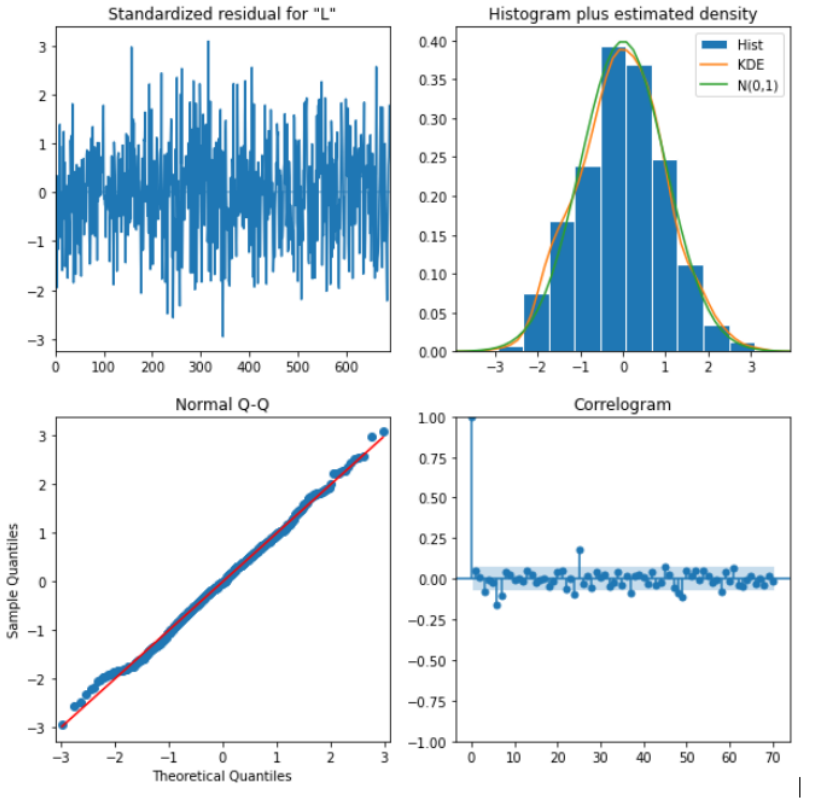

Modèle 3 : SARIMAX(EDF.LOGCONSO, order=(7, 0, 0), seasonal_order=(2, 0, 2, 24), trend=None)

SARIMAX Results

Dep. Variable:	LOGCONSO	No. Observations:	744
Model:	SARIMAX(7, 0, 0)x(2, 0, [1, 2], 24)	Log Likelihood	-203.658
Date:	Mon, 08 Jan 2024	AIC	431.316
Time:	15:18:24	BIC	485.739
Sample:	0 - 744	HQIC	452.369
Covariance Type:	opg		

	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-0.4379	0.039	-11.310	0.000	-0.514	-0.362
ar.L2	0.3091	0.042	7.433	0.000	0.228	0.391
ar.L3	-0.3397	0.044	-7.685	0.000	-0.426	-0.253
ar.L4	-0.1595	0.042	-3.816	0.000	-0.241	-0.078
ar.L5	0.2591	0.041	6.333	0.000	0.179	0.339
ar.L6	-0.2088	0.043	-4.836	0.000	-0.293	-0.124
ar.L7	-0.1966	0.040	-4.898	0.000	-0.275	-0.118
ar.S.L24	0.2652	0.069	3.832	0.000	0.130	0.401
ar.S.L48	0.7347	0.069	10.617	0.000	0.599	0.870
ma.S.L24	-0.4982	0.118	-4.216	0.000	-0.730	-0.267
ma.S.L48	-0.4711	0.107	-4.389	0.000	-0.681	-0.261
sigma2	0.0985	0.011	9.081	0.000	0.077	0.120

Ljung-Box (L1) (Q):	0.13	Jarque-Bera (JB):	1.27
Prob(Q):	0.72	Prob(JB):	0.53
Heteroskedasticity (H):	1.34	Skew:	0.08
Prob(H) (two-sided):	0.03	Kurtosis:	2.87

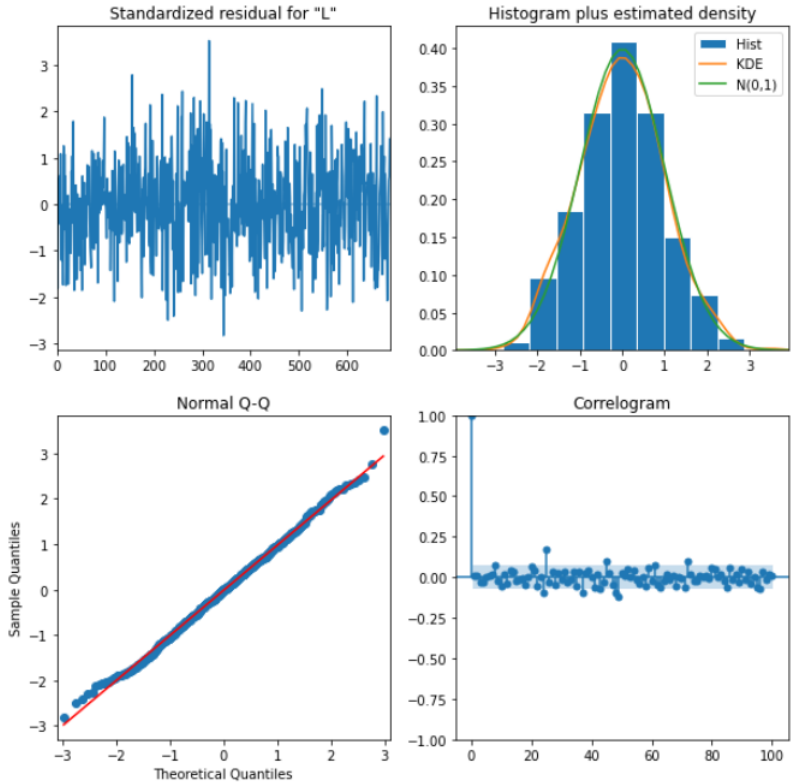

Modèle 4 : SARIMAX(EDF.LOGCONSO, order=(8, 1, 0), seasonal_order=(2, 0, 1, 24), trend=None)

SARIMAX Results

Dep. Variable:	LOGCONSO	No. Observations:	744
Model:	SARIMAX(8, 1, 0)x(2, 0, [1], 24)	Log Likelihood	-244.235
Date:	Mon, 08 Jan 2024	AIC	512.470
Time:	16:03:41	BIC	566.858
Sample:	0 - 744	HQIC	533.512
Covariance Type:	opg		

	coef	std err	z	P>|z|	[0.025	0.975]
ar.L1	-1.2711	0.037	-34.257	0.000	-1.344	-1.198
ar.L2	-0.7181	0.056	-12.884	0.000	-0.827	-0.609
ar.L3	-0.9057	0.060	-15.204	0.000	-1.022	-0.789
ar.L4	-0.8994	0.070	-12.803	0.000	-1.037	-0.762
ar.L5	-0.3917	0.071	-5.492	0.000	-0.531	-0.252
ar.L6	-0.4111	0.063	-6.574	0.000	-0.534	-0.288
ar.L7	-0.4329	0.061	-7.136	0.000	-0.552	-0.314
ar.L8	-0.1747	0.039	-4.494	0.000	-0.251	-0.099
ar.S.L24	0.6477	0.035	18.290	0.000	0.578	0.717
ar.S.L48	0.3538	0.035	10.010	0.000	0.285	0.423
ma.S.L24	-0.9914	0.232	-4.271	0.000	-1.446	-0.537
sigma2	0.1055	0.024	4.415	0.000	0.059	0.152

Ljung-Box (L1) (Q):	0.13	Jarque-Bera (JB):	0.77
Prob(Q):	0.72	Prob(JB):	0.68
Heteroskedasticity (H):	1.35	Skew:	0.01
Prob(H) (two-sided):	0.03	Kurtosis:	2.84

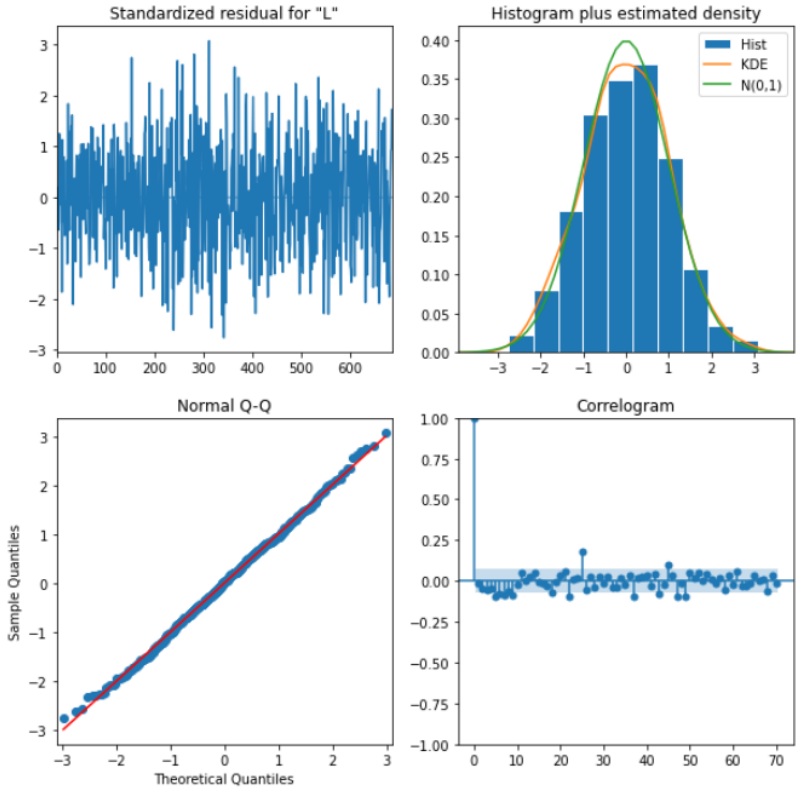

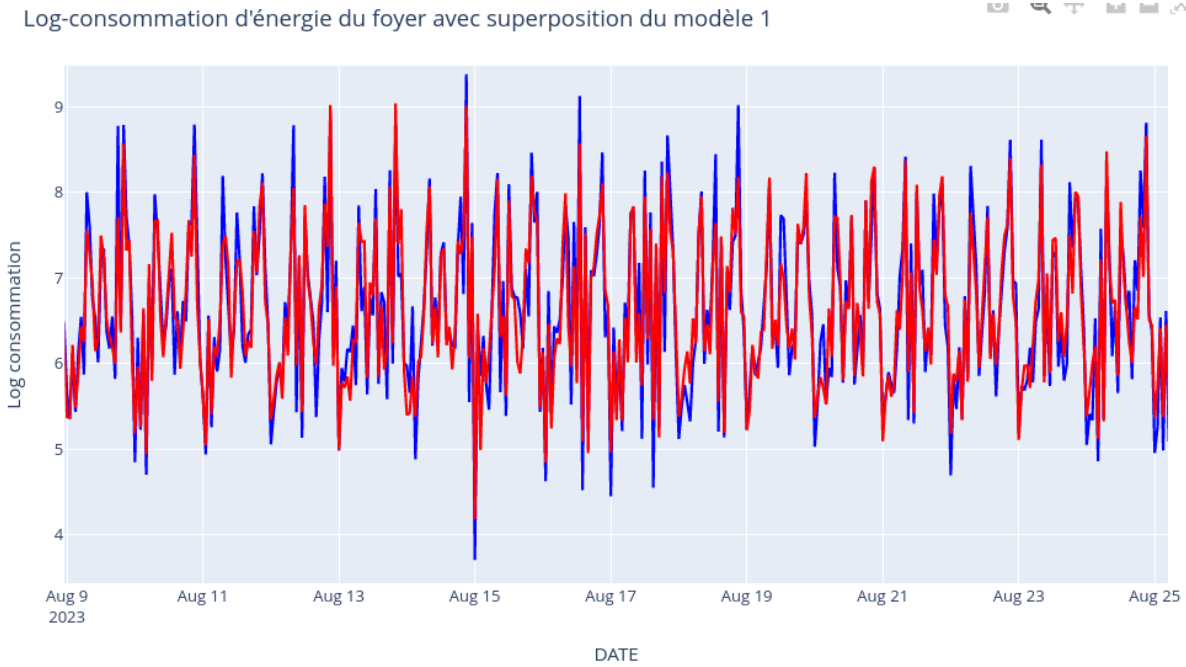
Log-consommation d'énergie du foyer avec superposition du modèle 1
Log consommation
9
8
7
6
5
4
Aug 9
2023
Aug 11
Aug 13
Aug 15
Aug 17
Aug 19
Aug 21
Aug 23
Aug 25
DATE

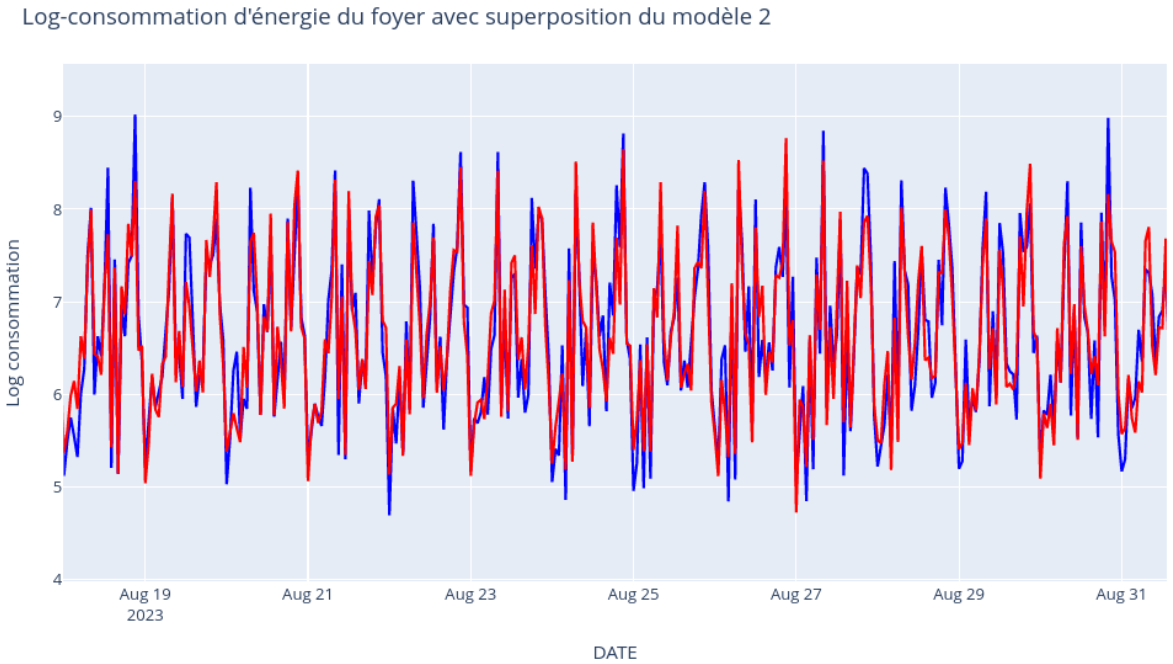
Log-consommation d'énergie du foyer avec superposition du modèle 2
Log consommation
9
8
7
6
5
4
Aug 19
2023
Aug 21
Aug 23
Aug 25
Aug 27
Aug 29
Aug 31
DATE

Log-consommation d'énergie du foyer avec superposition du modèle 3

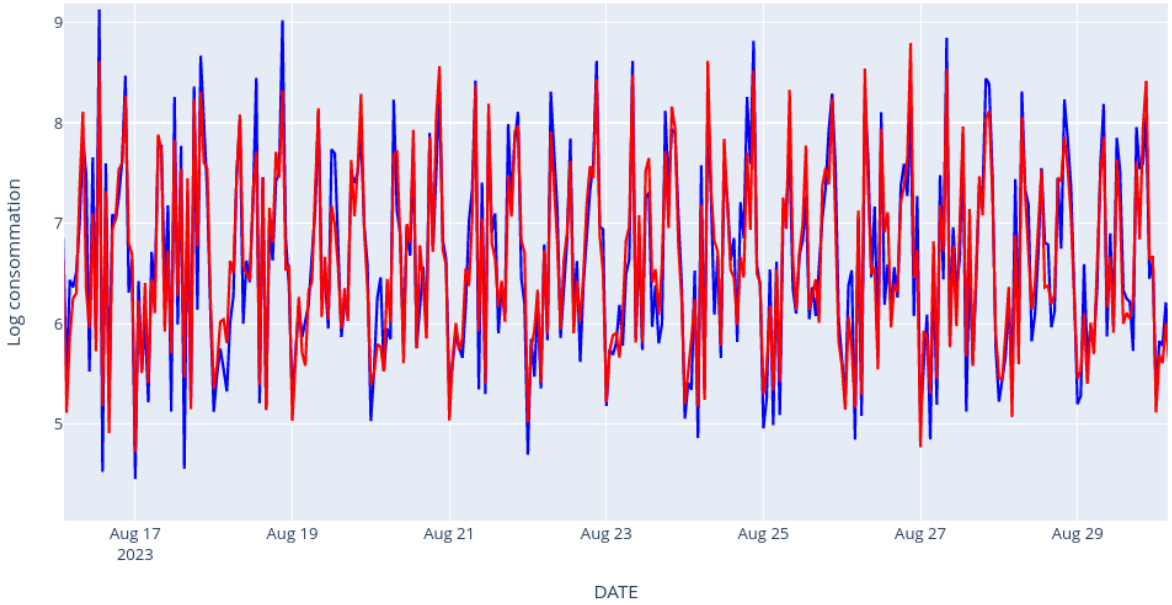

Log-consommation d'énergie du foyer avec superposition du modèle d2

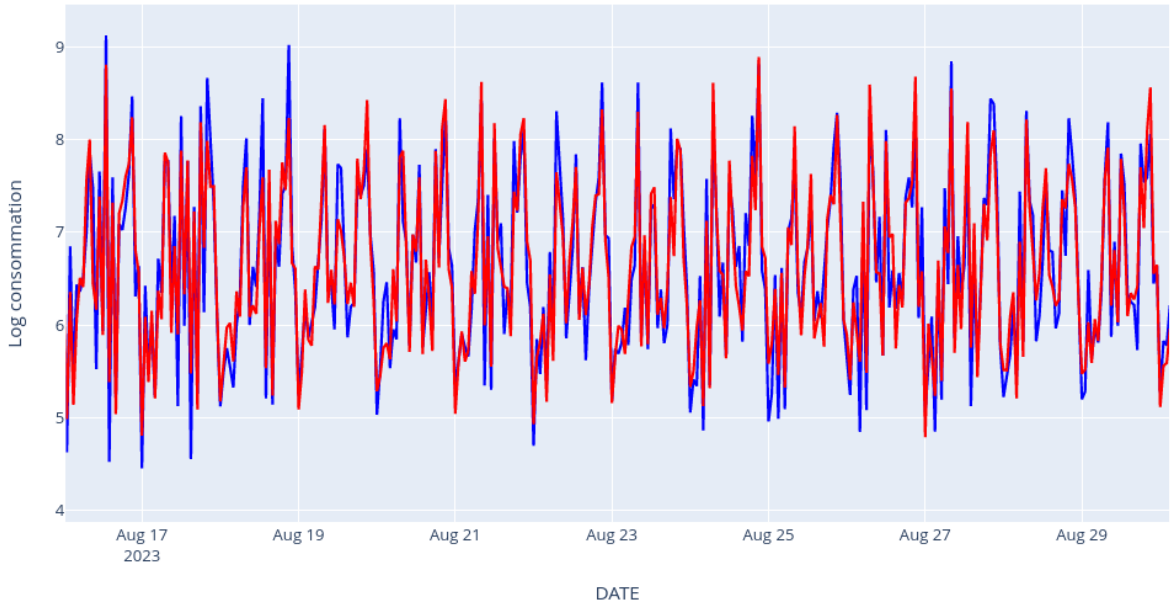

Cross validation : une partie train et une partie test, entraînement sur les données train

Train_test_split

```
M = len(EDF) - int(np.floor(0.2*len(EDF)))
print(M)
#Construire une partie train et une partie test avec 20% des données
EDF_Train = EDF.iloc[:M]
EDF_Test = EDF.iloc[M:]
```

```
596
```

Test dataset correspondant à 20% des données

Entraînent de 4 modèles choisis

```
Mod1 = SARIMAX(EDF_Train.LOGCONSO, order=(5, 0, 0), seasonal_order=(1, 0, 2, 24),
               enforce_stationarity=False, enforce_invertibility=False)
Mod1 = Mod1.fit()

Mod2 = SARIMAX(EDF_Train.LOGCONSO, order=(5, 0, 0), seasonal_order=(2, 0, 2, 24),
               enforce_stationarity=False, enforce_invertibility=False)
Mod2 = Mod2.fit()

Mod3 = SARIMAX(EDF_Train.LOGCONSO, order=(7, 0, 0), seasonal_order=(2, 0, 2, 24),
               enforce_stationarity=False, enforce_invertibility=False)
Mod3 = Mod3.fit()

Mod4 = SARIMAX(EDF_Train.LOGCONSO, order=(8, 1, 0), seasonal_order=(2, 0, 1, 24),
               enforce_stationarity=False, enforce_invertibility=False)
Mod4 = Mod4.fit()

## Stocker les modèles dans un dictionnaire

Mod = {"Mod1":Mod1,"Mod2":Mod2,"Mod3":Mod3,"Mod4":Mod4 }
```

Prédiction sur la partie test et évaluation avec certaines métriques

```python
def mean_absolute_percentage_error(y_true, y_pred):
    """Renvoie un pourcentage moyen d'erreur entre les vraies valeurs et les prédictions """
    y_true, y_pred = np.array(y_true), np.array(y_pred) #convertir au format array
    return np.mean(np.abs((y_true - y_pred) / y_true)) * 100


MAE = [] ## l'écart absolue moyen
MSE = [] ## la norme2 au carré moyenne
RMSE = []
MAPE = []

for i in range(1,5):
    """Rajoute une colonne prédiction pour chaque modèle et stock les métriques de validations"""

    EDF_Test[f"val_{i}"] = Mod[f"Mod{i}"].get_forecast(steps=len(EDF_Test)).summary_frame(alpha=0.05)['mean']
    #mean représente la meilleure estimation de chaque période
    MAE.append(mean_absolute_error(EDF_Test.LOGCONSO, EDF_Test[f"val_{i}"]) )
    MSE.append(mean_squared_error(EDF_Test.LOGCONSO, EDF_Test[f"val_{i}"]) )
    RMSE.append(mean_squared_error(EDF_Test.LOGCONSO, EDF_Test[f"val_{i}"],squared=False) )
    MAPE.append(mean_absolute_percentage_error(EDF_Test.LOGCONSO, EDF_Test[f"val_{i}"]) )
```

Dataset test complété avec les prédictions sur la partie test "Forcast_test"

	DATE	CONSO	LOGCONSO	val_exp1	val_exp2	val_exp3	val_exp4	val_1	val_2	val_3	val_4
596	2023-08-25 20:00:00	2789.791163	7.933722	1624.389878	1629.588951	1665.508527	1614.771569	7.346593	7.348657	7.373237	7.335164
597	2023-08-25 21:00:00	3990.209681	8.291599	5233.517739	5005.995358	5020.073489	5037.519473	8.516545	8.470966	8.476551	8.472884
598	2023-08-25 22:00:00	1947.497008	7.574300	819.634774	850.045620	843.339294	856.909432	6.662565	6.697864	6.692721	6.701547
599	2023-08-25 23:00:00	420.785554	6.042123	756.884070	718.223462	663.115417	705.827171	6.582916	6.529355	6.452301	6.507585
600	2023-08-26 00:00:00	294.629097	5.685717	187.620215	176.405297	183.159721	194.259237	5.188126	5.125359	5.165710	5.217408

Remarque

Le meilleur modèle sera celui qui minimise les métriques telles que la MAE et la MSE dans notre cas. En réalité, une métrique différente pourrait être choisie selon la demande d'un métier spécialiste sur la consommation d'électricité.

Comparaison des métriques pour l'évaluation des différents modèles

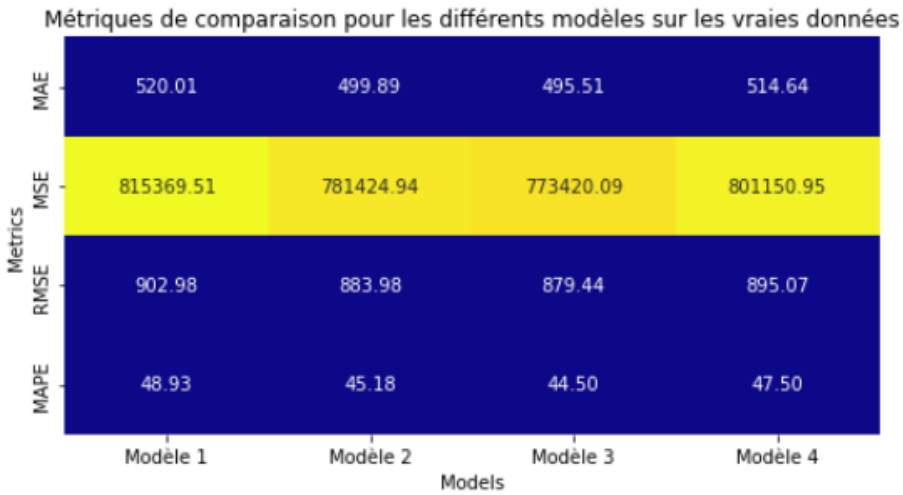

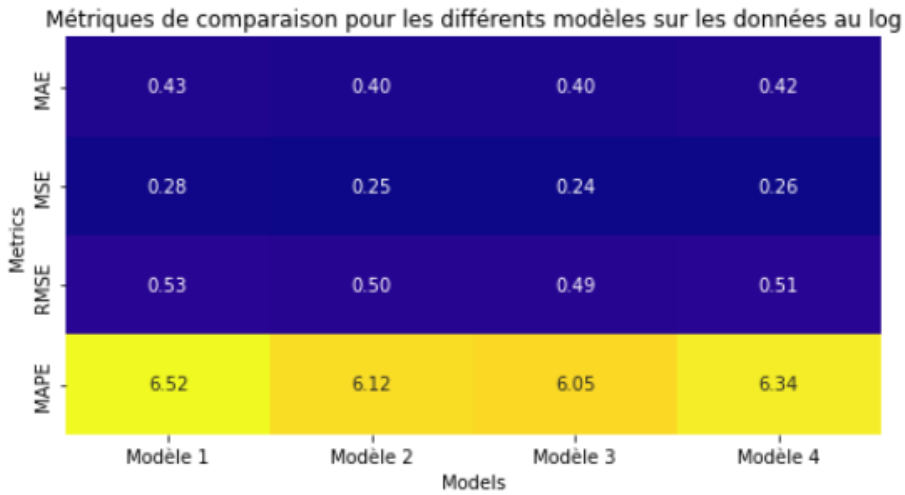

Prédiction sur la partie test et évaluation avec certaines métriques

```
pred_dates = pd.date_range(start='2023-09-01 00:00:00', periods=7*24, freq='H')  #Le temps futur
predictions = np.exp(Pred['mean'].values + Best_Mod.params["sigma2"]/2)  # les prédictions à venir

# Créer le graphique Plotly
fig = px.line(EDF, x='DATE', y='CONSO',
              labels={'CONSO': "Consommation d'électricité"})

# Ajouter les prédictions
fig.add_scatter(x=pred_dates, y=predictions, mode='lines',
                name='Prédictions', line=dict(color='green', dash='dot'))

# Ajouter la zone de confiance

##Zone supérieure
fig.add_scatter(x=pred_dates, y=np.exp(Pred['mean_ci_lower']), fill='tonexty',
                mode='lines', line=dict(color='lightgrey'), showlegend=False)
##Zone inférieure
fig.add_scatter(x=pred_dates, y=np.exp(Pred['mean_ci_upper']),
                fill='tonexty', mode='lines', line=dict(color='lightgrey'), showlegend=False)

# Mettre à jour le layout
fig.update_layout(title="Consommation d'électricité avec prédictions",
                  xaxis_title='Temps (en heure)',
                  yaxis_title='Consommation (en watt/heure)')

# Afficher le graphique
fig.show()
```

Représentation graphique des prédictions avec les intervalles de confiance à 95%

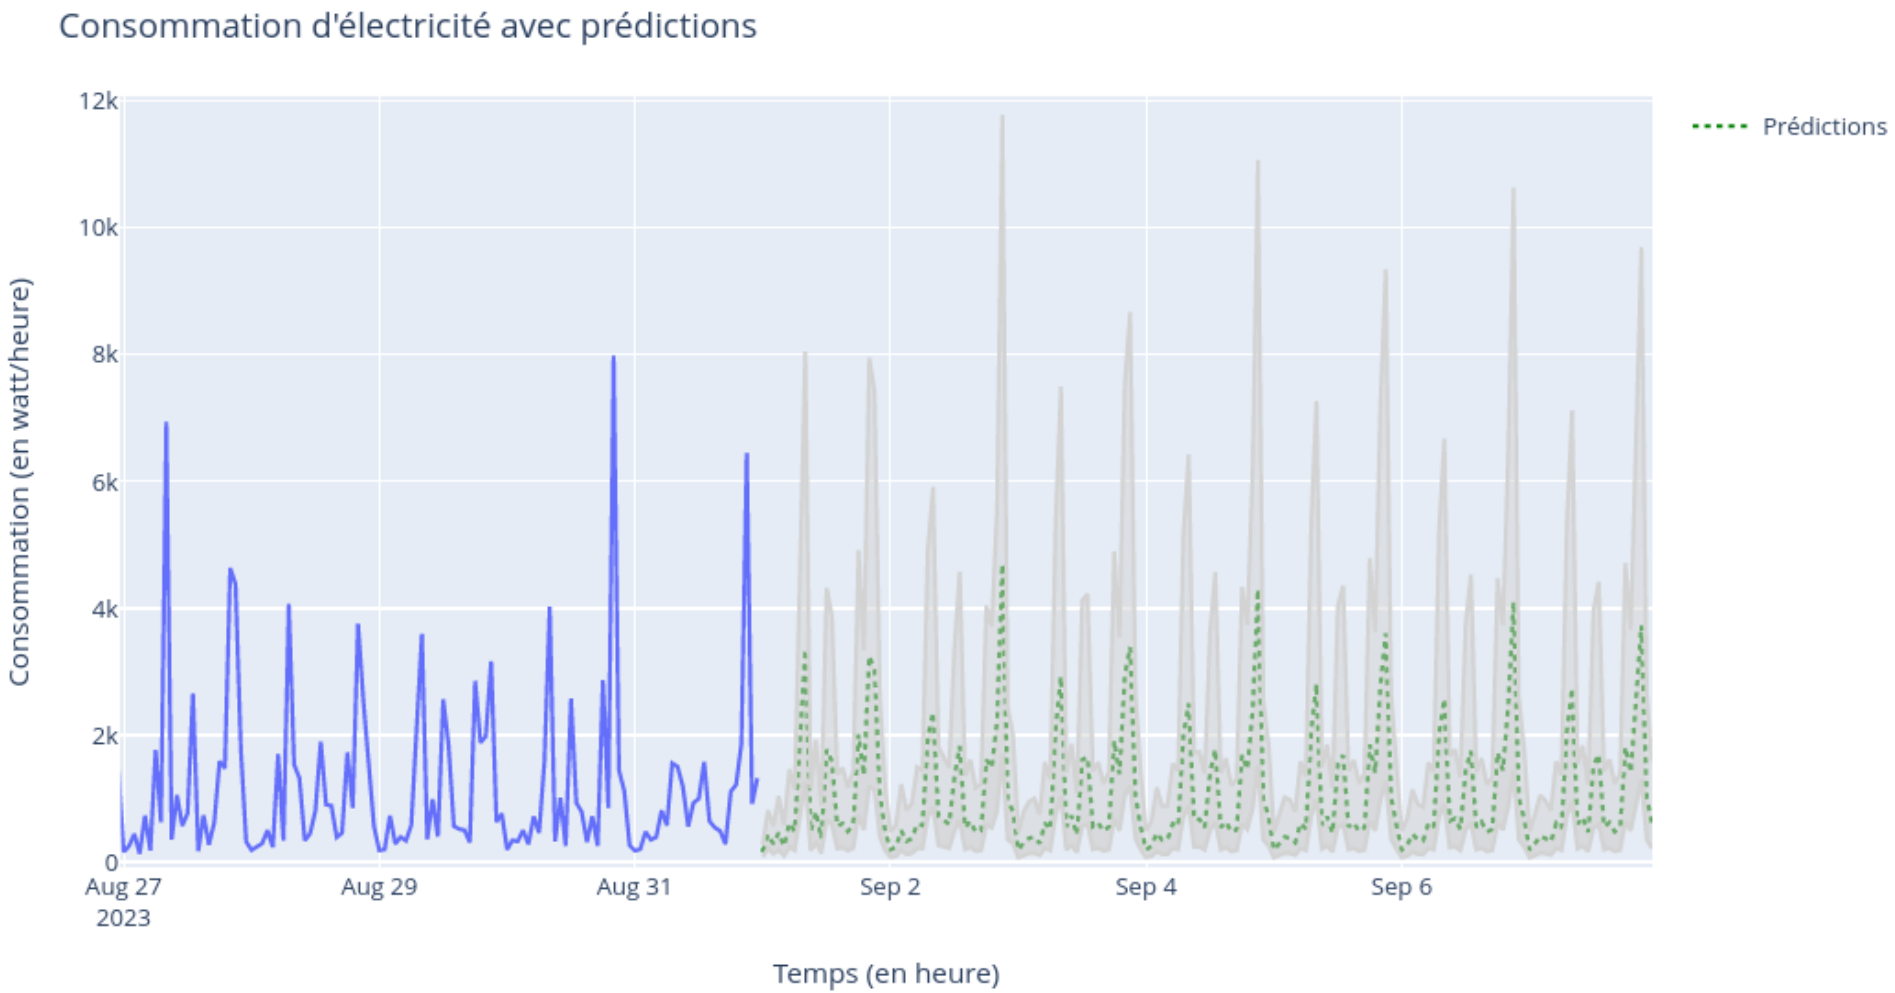

Conclusion

1. *La RMSE est relativement importante et l'indicateur MAPE sur les données réelle n'est pas non plus très bon (40% d'erreur en moyenne).*
2. *Le traitement des températures, la nébulosité ainsi que la pression atmosphérique pourraient être intégrés dans notre modèle.*
3. *Trouver le caractère saisonnier avec une méthode plus précise comme la transformée de Fourier.*
4. *Tester d'autres méthodes pour traiter les données (ex : réseau de neurones RNN)*